

BIOSOUND GVR

多声部管弦乐版

平台功能与原理说明

从生物序列、三维结构与多组学指标到可追溯的六声部古典编配

适用对象 音乐初学者、生物信息学研究者、跨学科创作者与平台开发者。本文档依据《Transform from genes to music》综述的方法框架，覆盖全部界面功能、模态特异映射、六声部配器、GVR 约束、文件导出、科研边界和二次开发接口。

版本 2.0 | 2026 年 7 月 16 日 | 本地离线多声部版

工作目录：C:\Users\34591\Desktop\音乐基因转化\音乐工具开发

阅读导航

本手册从“如何立即使用”开始，再逐步解释数据如何变成音乐。只想生成作品的读者可重点阅读第 1–4 章；需要科研复现的读者应继续阅读第 5–11 章；准备修改代码的开发者请阅读第 12–14 章与附录。

- 第 1 章：平台定位、能力边界与快速启动
- 第 2 章：网页界面与完整操作流程
- 第 3 章：文本、FASTA、PDB 与 CSV 输入规范
- 第 4 章：试听、审计与全部导出功能
- 第 5 章：序列与理化特征提取原理
- 第 6 章：PDB 空间声像、接触图与粗粒化 NMA
- 第 7 章：表达、表观、代谢、质谱与关联数据声学化
- 第 8 章：六声部古典编配、独立谱表与音频合成
- 第 9 章：十二音列与 Generate–Verify–Repair
- 第 10 章：溯源、可复现性与科研使用
- 第 11 章：多类输入的完整示例工作流
- 第 12–14 章：故障排查、软件架构、测试与扩展
- 第 16 章：综述方法矩阵、已实现功能与尚未实现边界
- 附录：氨基酸映射、Trace 字段、GVR 报告与发布清单

最重要的科学边界 本平台输出的是规则明确、可审计的数据声学化模型，不是蛋白质或细胞直接发出的真实声音，也不替代结构测定、统计检验或临床判断。

1. 平台定位与快速启动

1.1 平台做什么

BioSound GVR 把一维生物序列、PDB 三维坐标、质谱峰或多组学指标编译为可同时发声的古典室内乐事件。默认编制包括生物主旋律、弦乐对位、大提琴结构低音、圆号和声场、中提琴内声部与竖琴结构重音。每个派生事件都保存主事件编号、来源位置、输入符号、理化特征、预期音级、音乐功能和 GVR 状态。

平台的核心价值不是把字母机械替换成音符，也不是在一条旋律上不断切换乐器，而是采用综述提出的层级框架：最重要的生物组织轴控制最重要的音乐组织轴；序列/坐标决定时间，身份或数值决定前景音高，结构与聚类决定声部和形式，质量与不确定性决定滤波、力度和清晰度，验证器阻止错误映射进入最终文件。

1.2 一分钟启动

1. 打开工作目录，双击“启动平台.bat”。
2. 第一次启动若尚无本地环境，程序会自动创建 .venv 并安装依赖；以后启动不会重复询问。
3. 浏览器自动打开 <http://localhost:8501>。平台不要求邮箱、注册、登录或云端账户。
4. 从左侧选择示例、粘贴序列或上传文件，设置音高策略和速度，然后点击“生成并验证”。
5. 在主页面试听，并按需下载 WAV、MIDI、MusicXML、PDF、Trace CSV 或 GVR JSON。

隐私 Streamlit 以 headless 本地模式运行，已关闭浏览器统计收集。上传或粘贴的数据只在当前计算机内处理。

1.3 能力边界

- 可以：教学演示、规则比较、数据质控的听觉辅助、跨学科创作、可复现原型研究。
- 不应直接用于：疾病诊断、结构预测结论、细胞质量的唯一判断、把悦耳程度解释为生物功能。

- 网页试听是可叠加的轻量古典乐器频谱近似；出版级音质应把多轨 MIDI 或多谱表 MusicXML 送入 Muse Sounds、专业管弦乐采样库或真实演奏。

2. 网页界面与完整操作流程

2.1 左侧输入与作曲设置

控件	作用	建议
数据来源	示例数据、粘贴序列、上传文件三选一	初次使用先选示例
序列名称	为纯文本序列生成 FASTA 标题	使用样本号或基因/蛋白名称
序列类型	自动识别、蛋白质、DNA、RNA	含模糊字符时手动指定
记录/链	多 FASTA 记录或多 PDB 链的选择器	每次处理一个记录
音高策略	生物物理映射、文献氨基酸映射、十二音列 GVR	科研比较时保存设置
调式	多利亚、五声、自然小调、半音阶	文献映射模式主要影响非蛋白输入
十二音列形式	P、I、R、RI	仅十二音列模式启用
速度/拍号	控制播放时间与小节组织	同批比较保持一致
最多生成事件	对超长输入进行等间隔抽样	研究报告中记录该值
古典编配层数	从 1 到 6 逐步加入对位、低音、圆号、中提琴和竖琴	需要完整效果时选 6
对位独立度	控制小提琴延迟、反向音区与主旋律的差异	初学者建议 0.70
随机种子	确定十二音列和可复现细节	同一实验固定种子
PDB NMA	有 CA 坐标时计算相对简正模式	大结构会自动抽样

2.2 生成以后看到什么

页面顶部给出输入点数、总音乐事件数、GVR 是否通过、自动修复次数、音频时长和独立声部数。下方四个标签页分别承担“听和下载”“逐音符追踪”“规则验证”“科学解释”四种任务。

- 试听与导出：播放可同时发声的立体声 WAV、查看当前编制与每声部事件数、查看特征曲线并下载全部产物。
- 生物—音乐轨迹：逐行查看声部、音乐功能、主事件 ID、来源位置、符号、起拍、时值、MIDI、音级、声像、乐器、状态和映射理由。
- GVR 与映射：检查硬规则是否通过、查看修复日志、核对氨基酸音高配置。
- 科学边界：查看 NMA 参数、CSV QC 假设和论文方法在本平台中的实现边界。

3. 输入格式与解析规则

3.1 直接粘贴序列

在“数据来源”选择“粘贴序列”。可直接粘贴一行或多行纯字母，也可以粘贴完整 FASTA。纯文本会自动加上由“序列名称”生成的 FASTA 标题；空格、数字和常见换行会在解析时清除。

```
>my_protein
MKTIIALSYIFCLVFADYKDDDDK

# 纯序列也可以：
ACGTACGTACGT
```

自动识别逻辑：字符集合仅属于 A/C/G/T/N 时判为 DNA；仅属于 A/C/G/U/N 时判为 RNA；其他情况判为蛋白质。若蛋白质只由 A、C、G、T 等少数氨基酸组成，自动识别可能误判，必须手动选择“蛋白质”。

3.2 FASTA

支持 .fa、.fasta、.faa、.fna。多记录 FASTA 会在“记录/链”控件中列出；平台每次生成其中一个记录。标题作为记录名，字符位置从 1 开始写入 Trace CSV。

3.3 PDB

PDB 解析器读取 ATOM/HETATM 中的 CA 原子，忽略非 A 构象的 alternate location，并按链和残基号去重。三字母残基转换为一字母代码；不能识别的残基记为 X。HELIX 与 SHEET 记录用于二级结构类别，其余残基记为 coil。

注意 没有 CA 原子、坐标列格式不合法或仅含配体的 PDB 无法进入蛋白质声学化。mmCIF 当前版本尚未支持。

3.4 CSV 的六种解释路径

1. 若存在 sequence、seq、protein_sequence 或 dna_sequence 列：把每行解析为独立序列。
2. 若同时存在 mz/m-z 与 intensity/abundance 类别：按质谱峰解释。
3. 若存在 p/pvalue、染色体或坐标列：按 GWAS/EWAS 类关联景观解释，位置进入时间， $-\log_{10}(p)$ 进入显著性。
4. 若存在 methyl、CpG、H3K、ChIP 或 chromatin 类数值列：按表观调控轨迹解释。
5. 若存在 metabolite/compound 与 abundance/intensity：按代谢丰度表解释，并在有置信度列时保留注释不确定性。
6. 以上均不匹配时，把数值矩阵启发式解释为转录组表达矩阵，并假定行为细胞、列为基因。

CSV 可用 UTF-8 或 GB18030。缺失值与无穷值会被替换为可计算数值。自动分类依赖列名，只是入口级启发式；正式分析前必须核对模态、矩阵方向、标准化、字段含义和单位。尤其是单细胞表达数据常以基因为行、细胞为列，需要先转置。

4. 试听、审计与导出功能

4.1 WAV 试听

网页生成 22.05 kHz、16 位、双声道 WAV。六个声部按各自起拍叠加，具有固定的古典乐器角色和基础舞台位置；PDB x 坐标在该基础上施加局部空间偏移。音频最长默认 150 秒，超出时仅试听被截断，MIDI、MusicXML 和 Trace 仍保留全部事件。

4.2 六类下载文件

格式	包含内容	典型用途
WAV	已渲染的双声道古典配器预览	快速试听、演示
MIDI	格式 1：速度轨 + 每声部独立轨道、通道、乐器和声像	DAW、专业音源、分轨编曲
MusicXML	每声部独立 Part、谱表、拍号、速度、歌词符号与乐器定义	MuseScore/Sibelius 总谱与分谱
PDF	由本机 MuseScore 从 MusicXML 排版	打印、分享、课堂展示
Trace CSV	逐音符来源与全部映射证书	复现、审计、统计
GVR JSON	元数据、检查、修复、NMA、音频参数	研究归档、程序读取

PDF 按钮需要本机安装 MuseScore 4。若检测不到 MuseScore，平台仍提供 MusicXML；用户可在任意兼容软件中手动导出 PDF。

5. 序列与理化特征提取原理

5.1 蛋白质特征

每个氨基酸按 Kyte–Doolittle 疏水性表赋值 h ，平台使用 $h_norm = clip((h + 4.5) / 9, 0, 1)$ 归一化。酸性残基 D/E 的电荷取 -1，碱性 K/R 取 +1，H 取 +0.25；分子质量按常见残基质量表归一化到 75–205 Da。

特征	进入音乐的主要通道	解释
氨基酸身份	文献音高或调式级数	保留字母/残基差异
疏水性	主旋律时值、内声部音区与和声色彩	局部理化差异的听觉代理
电荷	主旋律八度、力度与十二音列目标音区	正负电性的听觉对比
残基质量	当前写入特征层，供扩展	可用于后续密度或力度实验

5.2 DNA 与 RNA 特征

碱基身份 A/C/G/T(U)/N 被映射到所选调式的不同级数；G 或 C 的 GC 指示值控制高低音区，A 或 G 的 purine 指示值与 GC 加权形成 $value = 0.65 \times GC + 0.35 \times purine$ 。该设计让碱基身份、GC 与嘌呤/嘧啶差异进入不同音乐维度。

5.3 时值

PDB 有二级结构时：helix = 1 个四分音符拍，sheet = 1.5 拍，coil = 0.5 拍。只有序列时，疏水性高的残基通常为 0.5 拍，亲水性强的残基为 1 拍，中间区域为 0.75 拍。组学行的 detected_features 控制 0.5–1.5 拍。所有时值量化到 0.25 拍。

5.4 超长序列抽样

若输入长度 N 大于“最多生成事件” M ，步长 $\text{stride} = \text{ceil}(N/M)$ ，按 $0, \text{stride}, 2 \times \text{stride} \dots$ 选择数据点。Trace CSV 保存真实 `source_index`，因此抽样后的事件仍能回到原始位置。抽样用于控制浏览器试听成本，不代表滑动平均或统计汇总。

6. PDB 空间声像、接触图与粗粒化 NMA

6.1 三维坐标到左右声像

对每条链的 CA 坐标先减去质心。x 坐标按该链的 x 轴跨度归一化到 $[-1, 1]$ ：-1 为左，0 为中央，+1 为右。网页 WAV 使用等功率声像： $\text{left} = \cos((\text{pan}+1)\pi/4)$ ， $\text{right} = \sin((\text{pan}+1)\pi/4)$ 。因此耳机中左右能量连续变化，而不是简单开关。

6.2 接触度

任意两 CA 原子距离小于 $8 \text{ \AA}$ 且不为自身时记为一次接触。每个残基的接触数量在链内归一化到 0–1，主要影响音区与大提琴配器：高接触度更容易进入较厚重、较集中声部。 $8 \text{ \AA}$ 是粗粒化接触图常见量级，本平台把它作为可配置 MVP 规则，不等同于化学键。

6.3 粗粒化 NMA

平台以 CA 节点建立单位弹簧各向异性网络模型。距离不超过默认 $12 \text{ \AA}$ 的节点对建立弹簧，方向向量 d 形成 3×3 子块 $-\text{dd}^T/||d||^2$ ，再装配 $3N \times 3N$ Hessian。对 Hessian 求特征值，去除接近零的刚体模态，对正特征值 λ 取 $\text{sqrt}(\lambda)$ 作为相对频率尺度。

为避免大蛋白造成内存和时间爆炸，最多抽取约 220 个残基；平台记录 `sample_stride`、`sampld_residues` 和 `contacts`。最低最多 24 个非零模式按对数比例映射到 55–1760 Hz，并以低音弦乐/圆号式频谱作为安静背景。

不能过度解读 单位弹簧模型没有真实力常数、原子质量、溶剂和温度标定；映射后的 Hz 只保持模式间相对对数比例，不是蛋白质绝对振动频率。

7. 多组学、QC、质谱与统计景观声学化

7.1 表达矩阵 QC

对每一行计算 total_counts、detected_features 和 mitochondrial_fraction。线粒体列通过列名 MT- 或 MT_ 识别；线粒体比例 = 线粒体列总和 / 全部数值列总和。列方差最高的最多 20 个特征被当作 HVG 代理，行级 hvg_score 是这些列的均值再归一化。

线粒体比例越高，WAV 的低通截止频率越低：cutoff = 700 + (1 - mean_mito) × 9000 Hz。HVG 分数提高前景主旋律的力度和清晰度；基因/细胞簇的复调潜力在当前版本以对位、低音与和声层派生表示，而不是让数千个基因同时无筛选地发声。

QC 只是听觉审计 阈值、基因命名和矩阵方向与实验平台密切相关。MVP 规则不能替代 Scanpy/Seurat 等成熟流程；适合先听出异常，再回到统计图和原始计数验证。

7.2 质谱

m/z 四舍五入后 mod 12 得到音级；归一化 m/z 决定音区，强度决定力度，竖琴承担前景峰序列与显著结构重音。该映射保留相对峰序列与强弱，但不能让听者直接反演精确 m/z；精确数值应从 Trace CSV 读取。

7.3 表观组学

基因组坐标沿音乐时间展开，甲基化或染色质信号控制主特征、力度、和声密度与结构层。综述强调不同组蛋白标记应成为不同声部或音色类别；当前 MVP 先实现单轨数值入口和六声部结构派生，多标记文件仍应先整理为可区分列，并在 Trace 中保留列名。低信号可形成稀疏区，高信号形成较密集、较突出的事件。

7.4 代谢组

代谢物丰度进入局部强度与音高，注释置信度进入 uncertainty，从而降低力度或清晰度。必须牢记丰度不等于通量：堆积可能来自产生增加、消耗降低或运输变化。当前版本尚未读取反应图与同位素示踪方向，因此生成的是代谢状态声景，而不是通量音乐。

7.5 GWAS/EWAS 类关联数据

染色体/坐标决定事件时间， $-\log_{10}(p)$ 决定显著性与前景突出程度，效应方向进入音区趋势。显著事件可触发竖琴结构标记，但强音、尖锐或不协和只表示统计显著或偏离参考，不代表致病性、因果性或机制已被证明。LD 区块、可信集和多基因分数的完整区域建模属于后续扩展。

8. 音乐映射与古典配器

8.1 三种音高策略

模式	音级来源	生物特征仍控制
文献氨基酸映射	pitch_mapping.csv; 保留 Spinning Melodies 已知映射	电荷音区、时值、力度、配器、声像
生物物理映射	归一化值进入五声/多利亚/小调/半音阶	结构、QC、接触度与空间位置
十二音列 GVR	由序列和种子生成的 12 音级行	音区、节奏、力度、配器、声像

文献表未覆盖 C、I、N、W，因为原始丝蛋白构建体未使用全部 20 种氨基酸。本平台以 extended_inference 明确标记扩展值，避免把软件推断误称为文献事实。

8.2 六声部古典编配

声部	固定乐器	音乐功能	生物来源
V1_melody	长笛/双簧管/单簧管/竖琴等	前景生物主旋律	每个被抽样的原始序列或数据点
V2_counterpoint	小提琴	延迟轮唱与反向音区对位	主旋律事件的可追溯派生
V3_bass	大提琴	分组边界与持续结构低音	每个短语/数据窗口的锚点
V4_horn_harmony	圆号	长时值结构和声场	结构、功能或数值区块
V5_viola_harmony	中提琴	和声三度与内声部连续性	与圆号共享的区块锚点
V6_harp_accents	管弦竖琴	结构边界、接触峰、显著性重音	高接触、高值或短语起点

“古典编配层数”不是音量旋钮，而是结构开关：1 只保留主旋律，2 加入小提琴，3 加大提琴，4 加圆号，5 加中提琴，6 加竖琴。这样既满足感知节制，也允许用户逐层听清每类映射。不同声部可跨声部同时发声，但同一声部内部仍按时间线排列。

8.3 九种古典乐器与持久通道

内部名	中文	GM 程序 (1-based)	当前用途
flute	长笛	74	DNA 主旋律
clarinet	单簧管	72	RNA/表达矩阵主旋律
oboe	双簧管	69	蛋白质主旋律
bassoon	大管	71	扩展低音配器接口
french_horn	圆号	61	关联数据主旋律或结构和声
violin	小提琴	41	派生对位
viola	中提琴	42	表观主旋律或内声部
cello	大提琴	43	结构低音
orchestral_harp	竖琴	47	质谱/代谢主旋律与结构重音

每个 MusicXML Part 和 MIDI Track 只在开头设置一次持续乐器，不再在单通道上每个音符切换 Program Change。这是从旧版“单线换音色”到真实多声部总谱的关键改变。

8.4 对位、低音、和声与结构重音算法

- 对位：按 2-3 个主旋律事件抽取锚点，延迟 0.5 拍；普通调式采用三度及反向音区，十二音列采用 I 形式的对应位置。
- 低音：按约两小节形成窗口，主音/属音在大提琴音域持续到下一窗口。
- 圆号与中提琴：按更长区块形成持续和声场，分别承担根音/属功能与三度色彩。和声是艺术组织层，不应解释为分子稳定性。
- 竖琴：在二级结构变化、接触度峰、数值显著峰或短语起点演奏三音短琶音，作为可听的结构标记。

8.5 网页音色模型与厅堂反射

WAV 试听不依赖大型 SoundFont，而是用古典乐器典型谐波结构作轻量加法合成：长笛以基频为主，单簧管突出奇次谐波，双簧管具有较丰富高次谐波，弦乐采用递减谐波并加入轻微揉弦，圆号与大管突出低次谐波，竖琴使用指数衰减拨弦包络。六声部使用不同增益，混合后加入 37 ms 与 71 ms 的克制早期反射。

这能提供古典配器方向的本地预览，但不等于真实乐团采样。多轨 MIDI 可驱动 Muse Sounds、Kontakt、BBC Symphony Orchestra 等音源；多谱表 MusicXML 可在 MuseScore/Sibelius 中排总谱、分谱和进一步人工配器。

8.6 力度、声像与呼吸

力度限制在 MIDI 1–127 的安全范围内，各声部再按前景、对位、低音、和声和重音设置独立混合增益。默认每 24 个主旋律事件插入 0.25 拍呼吸空隙。大提琴和圆号偏左，中提琴偏右，小提琴偏右，竖琴接近中央；有 PDB 坐标时，x 轴声像以加权偏移叠加到舞台位置。

9. 十二音列与 GVR 原理

9.1 从生物序列得到十二音列

平台把“随机种子:序列内容:记录名”送入 SHA-256。用摘要前 12 个字节对 0–11 排序，得到确定性排列；相同输入和种子必定得到相同行。随后把第一音归零，构造标准行形式：P 为原形，I 对每个音级取 $-x \bmod 12$ ，R 反转顺序，RI 先倒影再逆行。

```
P = (p0, p1, ... p11)
I = (-p0, -p1, ... -p11) mod 12
R = reverse(P)
RI = reverse(I)
```

9.2 事件证书

每个 MusicEvent 至少包含 event_id、voice_id、role、parent_event_id、source_index、source_label、symbol、onset、duration、midi、velocity、pan、timbre、expected_pc、mapping_rule、

row_position、row_form、status 和 feature 字典。expected_pc 与 actual MIDI mod 12 分开保存；parent_event_id 把对位、低音、和声和重音连接回主旋律来源。

9.3 硬约束

规则	验证内容	失败后处理
H_mapping	实际音级 = 映射证书 expected_pc	保持音级投影到合法 MIDI
H_register	每个声部在自己的可演奏音域与全局 36–96 内	换八度，不改变音级
H_timeline	同一 voice_id 内不意外重叠；跨声部重叠合法	只顺延发生冲突的单一声部
H_duration	时值 > 0	设为 0.25 拍
H_trace	来源索引与标签存在	不可安全修复则应拒绝
H_row	十二音列位置与活动行一致	投影到目标行音级
H_aggregate	完整 12 音循环无提前重复	最终复检；失败不发布
H_event_id	所有事件编号全局唯一	不可安全修复则拒绝发布
H_parent	每个派生声部事件引用有效主事件	不可安全修复则拒绝发布

9.4 Generate–Verify–Repair–Release

- 1. Generate：规则生成器依据数据和设置提出事件。MVP 不需要在线 LLM。
- 2. Verify：对实际事件执行确定性硬规则，而不是读取生成器的自我声明。
- 3. Repair：按声部分组，只做保持生物约束的局部操作，如换八度保留音级、修正时值、顺延声部内部重叠。跨声部同时发声不会被错误消除。
- 4. Re-verify：对修复后的最终事件重新扫描。
- 5. Release：有任何剩余硬违规时不发布 WAV/MIDI/MusicXML。

与论文一致的谨慎表述 事件级约束通过不等于作品在所有音乐学层面都完全合法。平台报告的是已实现规则的通过状态，并保留可核查轨迹。

10. 溯源、可复现性与科研使用

10.1 最小复现包

一次正式实验至少保存：原始输入、pitch_mapping.csv、Trace CSV、GVR JSON、MusicXML/MIDI、软件版本、音高模式、调式、速度、拍号、事件上限、编配层数、对位独立度、随机种子、NMA 开关和截止距离。WAV 可重新渲染，因此不是唯一必需的源文件。

10.2 如何比较两个样本

- 固定音高模式、调式、速度、拍号、事件上限、种子和音域。
- 记录是否发生抽样，优先比较相同长度或采用一致窗口。
- 先比较 Trace 中的特征和事件统计，再讨论主观听感。
- 盲听时不要告诉听者样本标签，并收集可重复的评分维度。

10.3 可发表的准确措辞

推荐：本工具实施可配置、可追溯的规则声学化，并以确定性验证器检查事件级映射一致性。

不推荐：本工具无损还原蛋白质真实声音，或声音直接证明某种结构/疾病状态。

11. 多类输入的完整示例 workflow

11.1 直接粘贴蛋白质

1. 选择“粘贴序列”，输入名称。
2. 粘贴一字母蛋白质序列并手动选择“蛋白质”。
3. 音高策略选“文献氨基酸映射”，速度 96，拍号 4/4，编配层数 6，对位独立度 0.70。
4. 生成后先在“当前编制”确认 6 个独立声部，再在 Trace 核对 C/I/N/W 的扩展映射。
5. 下载多谱表 MusicXML、多轨 MIDI 和 Trace CSV，再用 MuseScore 生成 PDF。

11.2 DNA/RNA

使用生物物理映射和多利亚/五声音阶。观察 GC 碱基是否进入更高音区；比较样本时固定根音、速度与事件上限。若序列只含 A/C/G/T 但实际上是蛋白质，必须手动指定类型。

11.3 PDB

上传 PDB，选择链，启用 NMA。戴耳机观察声像是否随 x 坐标移动；在科学边界标签查看 sample_stride、contacts、相对本征值与映射频率。正式报告中注明 8 Å 接触阈值和 12 Å NMA 弹簧截断。

11.4 单细胞表达 CSV

确保行为细胞、列为基因，线粒体基因以 MT- 或 MT_ 开头。生成后核对 mean_mitochondrial_fraction 和 low-pass cutoff。听到沉闷仅表示当前 QC 规则被触发，必须回到线粒体比例、小提琴图和过滤阈值复核。

11.5 十二音列

选择“十二音列 GVR”，记录种子与 P/I/R/RI。生成后在 GVR 标签核对 tone_row、H_row、H_aggregate。若要比对两段序列的音列差异，固定种子；若要比对不同作曲变体，固定序列并改变种子。

11.6 表观、代谢或关联 CSV

先用清晰列名表达数据语义：表观信号使用 methyl/CpG/H3K/ChIP 类列名；代谢表至少包含 metabolite/compound 与 abundance；关联数据至少包含 pvalue 与 chromosome/position。生成后先核对 record.data_type 和输入元数据，再讨论声学结果。若自动分类错误，应整理列名或在导入前转换数据，而不是依据听感猜测模式。

12. 故障排查

现象	常见原因	处理
启动后没有网页	8501 端口占用或环境未安装	关闭旧实例；查看命令窗口；必要时重建 .venv
第一次安装很慢	需要下载 Streamlit 依赖	保持联网；安装完成后可离线使用
序列被识别成 DNA	蛋白质字符集合碰巧只含 A/C/G/T	在序列类型中手动选蛋白质
PDB 报无 CA	文件只有配体、mmCIF 或列格式异常	换标准 PDB；确认存在 ATOM ... CA
CSV QC 不合理	行列方向或基因名不符	转置矩阵；统一 MT- 命名；核对数值列
PDF 按钮不可用	没有 MuseScore 4 或路径不同	下载 MusicXML 手动导出；安装/定位 MuseScore
试听被截断	总时长超过 150 秒	提高速度、减少事件；完整谱仍在导出文件
声音不够真实	网页使用轻量音色模型	把 MIDI/MusicXML 导入专业古典管弦乐音源
仍像单声部	编配层数为 1，或播放器忽略多轨/多谱表	将层数设为 6；在 MuseScore/DAW 检查 6 个 Part/Track
GVR 拒绝发布	修复后仍有硬违规	查看 violations_after 与 Trace，不要绕过门控

停止平台 关闭启动时保留的命令窗口，或在窗口按 Ctrl+C。浏览器页面关闭并不会自动停止本地服务。

13. 软件架构与文件职责

平台采用数据模型—控制引擎—界面/输出的分层结构。解析器只负责把外部文件变成 BioRecord；特征层补充数值；映射器提出 MusicEvent；GVR 决定能否发布；合成与导出层只消费通过检查的事件。

```
Input → parsers.py → BioRecord → features.py
      → mapping.py → MusicEvent[] → gvr.py
```

→ synth.py / exporters.py → WAV / MIDI / MusicXML / PDF / Trace

文件	职责
app.py	Streamlit 中文界面、文本输入、试听、下载和科学说明
models.py	BioRecord、MusicEvent、Violation、GVRReport 数据结构
parsers.py	FASTA、PDB、CSV 解析与格式识别
features.py	理化特征、PDB 声像/接触度、粗粒化 NMA
mapping.py	模态特异音高、六声部派生、音域、十二音列与事件生成
gvr.py	按声部硬约束验证、局部修复、软齐奏提示和最终门控
synth.py	古典乐器频谱近似、多声部混合、舞台声像、QC 滤波、WAV
exporters.py	多轨 MIDI、多 Part MusicXML、MuseScore PDF、GVR JSON
pipeline.py	稳定的端到端 Python API
config/pitch_mapping.csv	20 种氨基酸音高及事实/推断状态
tests/test_pipeline.py	FASTA、PDB、CSV、十二音列回归测试
.streamlit/config.toml	高对比主题、headless 与关闭统计提示

13.1 Python API

```
from biomusic.pipeline import SonificationSettings, run_pipeline

settings = SonificationSettings(
    pitch_mode='十二音列 GVR', row_form='RI', seed=42,
    texture_density=6, counterpoint_strength=0.70
)
result = run_pipeline('sample.fasta', fasta_bytes, settings)
assert result.report.passed
Path('sample.mid').write_bytes(result.midi)
```

14. 测试、验收与后续扩展

14.1 当前自动化测试

- FASTA：完整生成、WAV RIFF、多轨 MIDI、多 Part MusicXML 与 GVR JSON。
- 十二音列：Rl 行、前 12 音顺序、H_row 和 tone_row。
- PDB：空间声像、接触度与 NMA 可用性。
- CSV：线粒体比例、QC 低通和转录组类型。
- 配器：所有事件必须属于九种古典乐器白名单。
- 多声部：至少 5 个 Part、至少 6 个 MIDI Track（含速度轨）、跨声部存在同时发声、同声部无意外重叠。
- 界面：示例与文本粘贴生成、六项指标、当前编制表、GVR 通过。
- 启动：全新临时用户环境不出现邮箱或 onboarding 提示。

14.2 扩展建议

可以在不改变验证器的前提下替换 Generate：接入本地 Transformer/LSTM/LLM，让模型只提出节奏、织体和主题发展；expected_pc、source_index、行游标与最终门控仍由确定性代码控制。专业声音方向可接入 FluidSynth/SF2、Muse Sounds、Kontakt 或 OSC/Max/MSP/SuperCollider；空间音频可升级为经受试者校准的 HRTF。

15. 术语表

术语	通俗解释
声学化 / Sonification	把数据的变化系统地映射为可听参数
音级 / Pitch class	忽略八度后的 12 类音高，MIDI mod 12
寄存器 / Register	音符所在的高低音区
声像 / Panning	声音在左右声道之间的位置

术语	通俗解释
HVG	高变特征/高变基因，信息变化较大的列
NMA	简正模式分析，用线性化模型描述协同振动模式
GVR	Generate–Verify–Repair，生成—验证—修复
发布门控	只有最终硬规则全部通过才提供结果
Trace	把音符连接回原始数据和映射规则的证书
P/I/R/RI	原形、倒影、逆行、逆行倒影十二音列形式

16. 综述方法矩阵与本平台实现状态

16.1 综述提供的五条设计原则

1. 模态特异：DNA、表观、表达、蛋白、代谢与关联数据具有不同结构，不能共享一个万能字母—音符字典。
2. 层级对应：最重要的生物组织轴控制最重要的音乐组织轴。序列顺序应控制时间，折叠或网络结构应控制织体、空间和形式。
3. 感知节制：一次只选择少量可听辨变量；音高适合有序关系，节奏适合时间过程，音色适合类别，空间适合几何位置。
4. 一致与可追溯：同批样本使用相同规则；报告数据、预处理、参数、软件、Trace 与验证结果。
5. 比较与不确定性：优先在参考/突变、健康/疾病、处理/对照之间比较；低置信度不能被精美配器掩盖。

16.2 各数据模态如何进入当前六声部

模态	综述推荐的主要组织轴	当前已实现	仍待实现
----	------------	-------	------

模态	综述推荐的主要组织轴	当前已实现	仍待实现
DNA/RNA	碱基、密码子、阅读框、起止密码子、重复主题	序列→时间；碱基→音级；GC/嘌呤→音区与力度；六声部派生	三阅读框独立声部、起止门控、k-mer 主题检测
表观组	坐标、峰高/宽、标记类别、比较状态	列名识别；坐标→时间；信号→显著性与结构层	多组蛋白标记独立声部、峰宽、状态比较
转录组	时间点、簇、通路、细胞状态、伪时间	表达矩阵 QC；HVG/线粒体比例；多声部织体代理	正规归一化、聚类、PCA、GO 背景层、伪时间分支
蛋白/PDB	序列、理化、二级结构、三维接触、振动	氨基酸音高；疏水/电荷；HELIX/SHEET 时值；接触度；声像；粗粒化 NMA	实验 NMR、真实力常数、构象系综、结合位点/修饰
质谱/代谢	峰、丰度、置信度、通量、通路、网络拓扑	m/z、强度、丰度、置信度入口；竖琴与区块编配	同位素通量、反应方向、通路图、中心性/模块
GWAS/EWAS	坐标、显著性、效应、LD、可信集、多基因结构	坐标→时间；p 值→显著性；效应→音区；显著峰重音	LD 区块和声场、可信集、跨性状/组织富集

16.3 为什么采用“主旋律 + 派生声部”

综述反复指出，高维数据不应被压成孤立单音，但把全部变量同时映射又会形成不可理解的噪声。当前版本采取折中：原始数据点只生成一条信息最密集的前景主旋律，其余乐器从主事件、分组窗口、结构边界与显著峰派生。这样既产生真正复调，又能让每个派生音回到唯一的 parent_event_id。

艺术层与分析层必须分开 三度和声、主属低音、轮唱与厅堂反射用于可听性和音乐组织；它们不是由分子力学唯一决定的生物事实。Trace 中的 mapping_rule 会明确标注“派生”“区块”或“结构重音”，避免把配器选择误当成实验测量。

16.4 NMA、十二音列与 AI 的准确定位

PDB 粗粒化 NMA 提供相对模式背景，十二音列 GVR 提供可审计的音级硬约束，两者解决不同问题。前者近似结构动力学，后者约束符号作曲。当前版本不调用在线 LLM；未来可以让本地模型

提出节奏、织体或主题发展，但 expected_pc、source_index、voice_id、parent_event_id 和发布门控仍应由确定性代码掌握。

16.5 综述来源与引用方式

本章的方法框架直接依据本地综述《Transform from genes to music》，特别是 genomic、epigenomic、transcriptomic、proteomic、metabolomic、association-study 与 cross-modality design principles 各节。正式论文中应引用综述所列的原始文献，而不是只引用本软件手册。

附录 A：氨基酸音高映射

MIDI 与科学音高来自 config/pitch_mapping.csv。explicit 表示补充材料明确给出；explicit_from_TS 表示来自 TS 连接段；inferred 表示根据复现逻辑推断；extended_inference 是为通用 20 氨基酸输入补充的软件映射。

符号	名称	MIDI / 音高	状态
A	Ala	81 / A5	inferred
R	Arg	74 / D5	explicit
N	Asn	65 / F4	extended_inference
D	Asp	62 / D4	explicit
C	Cys	61 / C#4	extended_inference
Q	Gln	63 / Eb4	explicit
E	Glu	76 / E5	explicit
G	Gly	79 / G5	explicit
H	His	71 / B4	explicit
I	Ile	68 / Ab4	extended_inference
L	Leu	80 / Ab5	explicit
K	Lys	78 / F#5	explicit
M	Met	64 / E4	explicit
F	Phe	77 / F5	explicit
P	Pro	75 / Eb5	explicit
S	Ser	70 / Bb4	explicit
T	Thr	72 / C5	explicit_from_TS
W	Trp	68 / Ab4	extended_inference
Y	Tyr	90 / F#6	explicit
V	Val	73 / Db5	explicit
X	Unknown	60 / C4	fallback

附录 B : Trace CSV 字段

字段	含义
event_id	最终事件的全局唯一序号
voice_id/role	独立声部与音乐功能
parent_event_id	派生声部指向主旋律事件；主旋律为空
source_index/source_label	原始位置与人类可读标签
symbol	氨基酸、碱基、cell 或 peak
onset_quarter/duration_quarter	以四分音符为单位的起拍与时值
midi/pitch_class	实际音高与实际音级
expected_pc	生物映射或十二音列证书要求的音级
velocity/pan	力度和左右声像
timbre	九种古典配器内部名称
row_position/row_form	十二音列位置与形式；非序列模式为空
status	retained 或 repaired
mapping_rule	该事件的音高、派生或结构规则摘要
hydropathy/charge/contact/value/uncertainty	进入音乐映射的主要数值特征

附录 C : GVR JSON 结构

```
{
  'metadata': {
    'record_name': '...', 'data_type': 'protein',
    'pitch_mode': '十二音列 GVR', 'audio': {...}, 'nma': {...}
  },
  'gvr': {
    'passed': true, 'checks': {'H_mapping': true, ...},
    'tone_row': [0, ...], 'repairs': [],
    'violations_before': [], 'violations_after': []
  }
}
```

```
}
```

附录 D：科研发布前检查清单

- ☐ 原始输入文件与校验值已归档。
- ☐ 软件版本、配置文件与随机种子已记录。
- ☐ 抽样步长、速度、拍号、音域、调式与音高模式已报告。
- ☐ PDB 接触/NMA 参数和科学边界已写入方法。
- ☐ CSV 的矩阵方向、MT 基因命名和 HVG 方法已经独立复核。
- ☐ Trace CSV 和 GVR JSON 与音频/谱面一起发布。
- ☐ 没有把网页预览音色描述成真实乐团采样。
- ☐ 没有把声学化结果描述成诊断或结构证明。
- ☐ 盲听评价报告了样本量、问题、随机化和评分标准。
- ☐ 最终 MusicXML 已在 MuseScore 中人工检查拍号、音符与配器文字。

附录 E：论文灵感与本平台实现的对应

方法参考：Dai et al., *Verifier-Guided Twelve-Tone Composition: A Generate–Verify–Repair Harness for Symbolic Music Generation*, *arXiv:2607.11334v2*, 2026；本地综述《Transform from genes to music》；以及本地 *Spinning Melodies* 复现中的 *pitch_mapping.csv* 逻辑。

论文/方法思想	平台实现	差异与边界
规范化事件记录	MusicEvent + voice/role/parent + Trace CSV	实现六声部并保留派生关系
Generate	可复现规则生成器	当前不调用在线 LLM
Deterministic Verify	H_mapping 等最终事件复检	只声明已实现规则
Row-preserving Repair	按声部换八度保音级、修时值、顺延内部重叠	没有 LLM patch/replan
Final release gate	violations_after 为空才发布	失败会明确报错
Trace	每个音符保存来源、证书和状态	计划层历史仍有限
十二音列 P/I/R/RI	SHA-256 确定行 + 四种形式	生物特征控制其他音乐维度